Optimizasyona Giriş

Ders Notları

Lecture 1: Optimizasyonun Temelleri

Bu notlar, temel türev ve integral bilen birine yönelik olarak,
her kavramı sıfırdan ve sezgisel olarak açıklamayı amaçlar.

İçindekiler

1 Optimizasyon Nedir? 4
1.1 En Basit Tanımıyla . . . 4
1.2 Optimizasyon Probleminin Genel Formu . . . 4
1.3 Sınıflandırma . . . 4
1.3.1 Minimizasyon vs Maksimizasyon . . . 4
1.3.2 Sürekli (Continuous) vs Ayrık (Discrete) . . . 4
1.3.3 Kısıtlı (Constrained) vs Kısıtsız (Unconstrained) . . . 4
1.3.4 Lineer vs Nonlineer . . . 4
1.3.5 Konveks (Convex) vs Non-Convex . . . 5
1.3.6 Global vs Lokal Çözüm . . . 5
1.4 Optimization Tree (Ağaç Yapısı) . . . 5

2 Konveks Kavramlar 6
2.1 Kombinasyonlar – Neden Önemli? . . . 6
2.2 Lineer Kombinasyon . . . 6
2.3 Affine Kombinasyon . . . 6
2.4 Konik (Conical) Kombinasyon . . . 6
2.5 Konveks (Convex) Kombinasyon . . . 6
2.6 Özet Tablosu . . . 6
2.7 Konveks Fonksiyon . . . 6

3 Kalkülüs Tekrarı 8
3.1 Yaklaşım Hızı (Rate of Convergence) . . . 8
3.1.1 Q-Linear (Doğrusal Yaklaşım) . . . 8
3.1.2 Q-Superlinear (Doğrusal-Üstü) . . . 8
3.1.3 Q-Order p (p. Dereceden) . . . 8
3.2 Lipschitz Sürekliliği . . . 8
3.3 Kısmi Türev ve Gradient . . . 8
3.3.1 Tek Değişkenli Türev . . . 8
3.3.2 Çok Değişkenli: Kısmi Türev . . . 8
3.3.3 Gradient . . . 9
3.3.4 Yönlü Türev (Directional Derivative) . . . 9
3.4 Hessian Matrisi . . . 9
3.5 Taylor Teoremi . . . 9
3.6 Jacobian . . . 9

4 Lineer Cebir Tekrarı 11
4.1 Vektör . . . 11
4.1.1 İç Çarpım . . . 11
4.1.2 Vektör Normları . . . 11
4.2 Özdeger ve Özvektör . . . 11
4.3 Simetrik Pozitif Definit (SPD) Matris . . . 11
4.4 Spectral Decomposition . . . 11
4.5 Tekil Değer Ayrışımı (SVD) . . . 11
4.6 LU Ayrışımı . . . 11
4.7 Cholesky Ayrışımı . . . 11
4.8 Koşul Sayısı (Condition Number) . . . 12
4.9 Sherman–Morrison–Woodbury Formülü . . . 12

5 Çözülmüş Örnekler **13**
5.1 Örnek 1: Gradient Hesaplama 13
5.2 Örnek 2: Hessian ve Pozitif Definitlik 13
5.3 Örnek 3: Taylor Açılımı 13
5.4 Örnek 4: Konvekslik Kontrolü 13
5.5 Örnek 5: Özdeger Bulma 13
5.6 Örnek 6: LU Ayrışımı 14
5.7 Örnek 7: Jacobian Hesaplama 14
5.8 Örnek 8: Koşul Sayısı 14
5.9 Örnek 9: Konveks Kombinasyon 14
5.10 Örnek 10: Minimumu Bul 14

Optimizasyon Nedir?

En Basit Tanımıyla

Optimizasyon= **en iyi değeri bulmak**.

Bir fonksiyonun **minimum** (en küçük) veya **maximum** (en büyük) değerini veren x'i arıyoruz.

$$\min_x f(x)$$

Örnek: $f(x) = x^2 - 4x + 5$ fonksiyonunun minimumunu bul.
Bildiğin türevi alıp sıfıra eşitle:

- $f'(x) = 2x - 4 = 0 \;\Rightarrow\; x = 2$
- $f(2) = 4 - 8 + 5 = 1$

$x = 2$'de minimum değer 1'dir. İşte optimizasyon bu kadar basit başlıyor!

Optimizasyon Probleminin Genel Formu

$$\min_x f(x) \quad \text{öyle ki (subject to)} \quad x \in \Omega$$

- $f(x)$**:** Amaç fonksiyonu (objective function) – minimize etmek istediğimiz şey
- x**:** Karar değişkeni (decision variable) – değiştirebildiğimiz değer
- Ω**:** Uygun bölge (feasible region) – x'in alabileceği değerler kümesi

Sınıflandırma

1.3.1 Minimizasyon vs Maksimizasyon

$\min f(x) = -\max(-f(x))$. Yani birini çözebildin mi, diğerini de çözersin. Hep **minimizasyon** üzerinden gideriz.

1.3.2 Sürekli (Continuous) vs Ayrık (Discrete)

- **Sürekli:** x herhangi bir reel sayı olabilir ($x = 3.14159\ldots$)
- **Ayrık:** x sadece tam sayı olabilir ($x = 1, 2, 3, \ldots$)
- Örnek: "Kaç kg şeker alayım?" $\rightarrow$ sürekli, "Kaç araba üreteyim?" $\rightarrow$ ayrık

1.3.3 Kısıtlı (Constrained) vs Kısıtsız (Unconstrained)

- **Kısıtsız:** x'e hiçbir sınır yok, istediğini seç
- **Kısıtlı:** x bazı koşulları sağlamalı (örneğin $x \geq 0$, veya $x_1 + x_2 = 10$)

1.3.4 Lineer vs Nonlineer

- **Lineer:** $f(x) = 3x_1 + 2x_2$ gibi (tüm terimlerin derecesi 1)
- **Nonlineer:** $f(x) = x_1^2 + \sin(x_2)$ gibi (kareli, trigonometrik vs.)

1.3.5 Konveks (Convex) vs Non-Convex

- **Konveks:** Fonksiyonun tek bir "çukuru" var → minimum bulduysan, o **global** minimumdur
- **Non-convex:** Birden fazla çukur olabilir → bulduğun minimum sadece **lokal** olabilir

1.3.6 Global vs Lokal Çözüm

- **Global minimum:** Tüm x'ler içinde en küçük $f(x)$ değeri
- **Lokal minimum:** Yakınındaki x'ler içinde en küçük $f(x)$ değeri

Örnek: $f(x) = x^4 - 2x^2 + 1$: $x = \pm 1$'de lokal (ve global) minimum, $x = 0$'da lokal maksimum var.

Optimization Tree (Ağaç Yapısı)

```
                  Optimization
                 /            \
         Continuous         Discrete
         /        \              \
  Unconstrained  Constrained   Integer Programming
       |          /    |    \
   (Line search, Linear  Network  Stochastic
    Trust region) Prog.  Prog.    Prog.
```

Bu derste öğreneceğimiz yöntemler:

1. **Kısıtsız optimizasyon:** Line search, Trust region, Conjugate gradient, Quasi-Newton
2. **Lineer programlama:** Simplex, Interior point
3. **Kısıtlı optimizasyon:** Quadratic programming, Penalty methods, Active set

Konveks Kavramlar

Kombinasyonlar – Neden Önemli?

Optimizasyonda "çözüm uzayının şekli" çok önemli. Eğer çözüm uzayın konveks ise, işimiz çok kolaylaşıyor çünkü lokal minimum= global minimum olur.

Lineer Kombinasyon

Elimizde vektörler var: $x_1, x_2, \ldots, x_p$ (bunlar $\mathbb{R}^n$'de noktalar)

$$x = \lambda_1 x_1 + \lambda_2 x_2 + \cdots + \lambda_p x_p$$

Katsayılar (λ_i) herhangi bir reel sayı olabilir: pozitif, negatif, sıfır...

Affine Kombinasyon

Lineer kombinasyonla aynı, AMA katsayıların toplamı 1 olmalı:

$$\sum_{i=1}^{p} \lambda_i = 1$$

Geometrik anlamı: İki nokta arasındaki **doğru** (ve onun uzantısı).

Konik (Conical) Kombinasyon

Katsayılar **negatif olamaz:** $\lambda_i \geq 0$.

Geometrik anlamı: Orijinden başlayan bir **koni** şeklinde bölge.

Konveks (Convex) Kombinasyon

Hem katsayıların toplamı 1, **hem** hepsi ≥ 0:

$$\sum_{i=1}^{p} \lambda_i = 1 \quad \text{ve} \quad \lambda_i \geq 0$$

Geometrik anlamı: İki nokta arasındaki **doğru parçası**. Üç nokta için **üçgen**.

Özet Tablosu

Kombinasyon	Koşul	Geometrik Anlam
Lineer	yok	Tüm uzay
Affine	$\sum \lambda_i = 1$	Noktalardan geçen doğru/düzlem
Konik	$\lambda_i \geq 0$	Orijinden koni
Konveks	$\sum \lambda_i = 1$ ve $\lambda_i \geq 0$	Noktaların içindeki bölge

Konveks Fonksiyon

Bir fonksiyon f **konveks** ise, herhangi iki noktası arasına çizdiğin doğru, fonksiyonun **üstünde** kalır:

$$f(\alpha x + (1-\alpha)y) \leq \alpha f(x) + (1-\alpha) f(y) \quad \forall \alpha \in [0,1]$$

Örnekler:

- $f(x) = x^2 \to$ konveks ✓ (parabol yukarı bakıyor)

- $f(x) = |x| \to$ konveks ✓ (V şeklinde)
- $f(x) = e^x \to$ konveks ✓
- $f(x) = -x^2 \to$ konveks değil, **konkav**

Neden önemli? Konveks fonksiyonun minimumunu bulursan, o **kesinlikle global minimumdur**.

Kalkülüs Tekrarı

Yaklaşım Hızı (Rate of Convergence)

Optimizasyon algoritmaları **iteratif** çalışır. $\{x_k\}$ dizisi x^*'a yaklaşıyor olsun:

3.1.1 Q-Linear (Doğrusal Yaklaşım)

$$\frac{\|x_{k+1} - x^*\|}{\|x_k - x^*\|} \leq r \quad , \; r \in (0, 1)$$

Her adımda hatayı **sabit bir oranla** azaltırsın. Örnek: $r = 0.5$ ise hata: $1 \to 0.5 \to 0.25 \to 0.125 \to \ldots$

3.1.2 Q-Superlinear (Doğrusal-Üstü)

$$\lim_{k\to\infty} \frac{\|x_{k+1} - x^*\|}{\|x_k - x^*\|} = 0$$

Oran giderek küçülüyor.

3.1.3 Q-Order p (p. Dereceden)

$$\frac{\|x_{k+1} - x^*\|}{\|x_k - x^*\|^p} \leq M$$

$p = 2$ ise **kuadratik yaklaşım**: hata her adımda **karesi** kadar azalır. Newton metodu bunu başarır!

Lipschitz Sürekliliği

f, $\mathcal{N}$ kümesinde **Lipschitz sürekli** ise:

$$\|f(x) - f(y)\| \leq L\|x - y\| \quad \forall x, y \in \mathcal{N}$$

Fonksiyonun değişim hızı **sınırlı**. L ne kadar küçükse, fonksiyon o kadar "yavaş" değişir.

Kısmi Türev ve Gradient

3.3.1 Tek Değişkenli Türev

$f(x) = x^3 \;\Rightarrow\; f'(x) = 3x^2$

3.3.2 Çok Değişkenli: Kısmi Türev

$f(x_1, x_2)$ gibi fonksiyonlarda, bir değişkene göre türev alırken diğerlerini sabit tutarsın.
Örnek: $f(x_1, x_2) = x_1^2 + 3x_1x_2 + x_2^2$

$$\frac{\partial f}{\partial x_1} = 2x_1 + 3x_2, \qquad \frac{\partial f}{\partial x_2} = 3x_1 + 2x_2$$

3.3.3 Gradient

Tüm kısmi türevleri bir vektör içinde toplarsak **gradient**:

$$\nabla f(x) = \begin{pmatrix} \partial f/\partial x_1 \\ \partial f/\partial x_2 \\ \vdots \\ \partial f/\partial x_n \end{pmatrix}$$

Gradient, fonksiyonun **en hızlı arttığı yönü** gösterir. $-\nabla f$ ise **en hızlı azaldığı yön** $\rightarrow$ minimuma gitmek için bu yönde yürü!

3.3.4 Yönlü Türev (Directional Derivative)

$$D(f(x), p) = \nabla f(x)^T p$$

Hessian Matrisi

Hessian= **ikinci türevlerin matrisi**:

$$\nabla^2 f(x) = \begin{pmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \cdots \\ \vdots & \vdots & \ddots \end{pmatrix}$$

Örnek: $f(x_1, x_2) = x_1^2 + 3x_1x_2 + x_2^2$

$$\nabla^2 f = \begin{pmatrix} 2 & 3 \\ 3 & 2 \end{pmatrix}$$

Hessian ne işe yarar?

- Hessian pozitif definit $\rightarrow$ o nokta **minimum** (çukur)
- Hessian negatif definit $\rightarrow$ o nokta **maksimum** (tepe)
- Karışık $\rightarrow$ **eyer noktası** (ne min ne max)

Taylor Teoremi

Tek değişkende: $f(x+h) \approx f(x) + f'(x)h + \frac{1}{2}f''(x)h^2$

Çok değişkende (2. derece):

$$f(x+p) = f(x) + \nabla f(x)^T p + \frac{1}{2} p^T \nabla^2 f(x + \alpha p)\, p$$

Neden önemli? Optimizasyon algoritmaları fonksiyonu Taylor açılımı ile yaklaştırıp minimum bulur.

Jacobian

$r : \mathbb{R}^n \rightarrow \mathbb{R}^m$ için Jacobian $m \times n$ matristir:

$$J(x) = \begin{pmatrix} \nabla f_1(x)^T \\ \nabla f_2(x)^T \\ \vdots \\ \nabla f_m(x)^T \end{pmatrix}$$

Örnek: $r(x_1, x_2) = (x_1^2 + x_2,\ x_1 x_2)$

$$J = \begin{pmatrix} 2x_1 & 1 \\ x_2 & x_1 \end{pmatrix}$$

Lineer Cebir Tekrarı

Vektör

Bir kolon vektör $x \in \mathbb{R}^n$. Transpose: $x^T = (x_1, x_2, \ldots, x_n)$.

4.1.1 İç Çarpım

$x^T y = \sum_{i=1}^{n} x_i y_i$

4.1.2 Vektör Normları

Norm	**Formül**	**Anlam**	$x = (3, -4)$
1-norm	$\|x\|_1 = \sum \|x_i\|$	Mutlak değerlerin toplamı	7
2-norm	$\|x\|_2 = \sqrt{\sum x_i^2}$	Öklid uzunluğu	5
∞-norm	$\|x\|_\infty = \max \|x_i\|$	En büyük eleman	4

Özdeger ve Özvektör

A bir $n \times n$ matris. Eğer sıfır olmayan bir x vektörü için:

$$Ax = \lambda x$$

ise, λ **özdeger**, x **özvektör**.

Ne demek? A matrisi x'in **yönünü değiştirmiyor**, sadece λ katı büyütüyor/küçültüyor.

Özdegerleri bulma: $\det(A - \lambda I) = 0$ denklemini çöz.

Simetrik Pozitif Definit (SPD) Matris

A **simetrik pozitif definit** ise:

1. $A^T = A$ (simetrik)
2. Tüm özdegerleri **pozitif** ($\lambda > 0$)

Eşdeğer tanım: Her sıfır olmayan x için $x^T A x > 0$.

Neden önemli? $f(x)$'in Hessian'ı SPD ise $\rightarrow$ o nokta kesinlikle **minimum**!

Spectral Decomposition

A simetrik ise: $A = Q \Lambda Q^T$ (Q ortogonal, Λ köşegen).

Tekil Değer Ayrışımı (SVD)

Herhangi bir $m \times n$ matris A için: $A = U \Sigma V^T$.

LU Ayrışımı

$PA = LU$ (L: alt üçgensel, U: üst üçgensel, P: permütasyon).

Çözüm: $Ly = Pb$ (ileri yerine koyma), sonra $Ux = y$ (geri yerine koyma).

Cholesky Ayrışımı

A SPD ise: $P^T A P = L L^T$. LU'ya göre **2 kat hızlı**.

Koşul Sayısı (Condition Number)

$$\kappa(A) = \|A\| \cdot \|A^{-1}\|$$

$\kappa(A)$ büyükse $\rightarrow$ A **kötü konumlanmış** (ill-conditioned). Küçük hatalar sonucu çok değiştirebilir.

Sherman–Morrison–Woodbury Formülü

$\hat{A} = A + uv^T$ ise:

$$\hat{A}^{-1} = A^{-1} - \frac{A^{-1}uv^TA^{-1}}{1 + v^TA^{-1}u}$$

Quasi-Newton yöntemleri her adımda Hessian'a rank-1 güncelleme yapar. Bu formül sayesinde her seferinde tersi sıfırdan hesaplamak gerekmez!

Çözülmüş Örnekler

Örnek 1: Gradient Hesaplama

Soru: $f(x_1, x_2) = 2x_1^2 + x_1x_2 + x_2^2$ fonksiyonunun gradientini bul ve $(1, 2)$ noktasında hesapla.

Çözüm:

$$\nabla f(x) = \begin{pmatrix} 4x_1 + x_2 \\ x_1 + 2x_2 \end{pmatrix}, \qquad \nabla f(1, 2) = \begin{pmatrix} 6 \\ 5 \end{pmatrix}$$

Yorum: Minimum bulmak için $(-6, -5)$ yönünde yürümeliyiz.

Örnek 2: Hessian ve Pozitif Definitlik

Soru: $f(x_1, x_2) = 3x_1^2 - 2x_1x_2 + x_2^2$ fonksiyonunun Hessianını bul. Pozitif definit mi?

Çözüm:

$$\nabla^2 f = \begin{pmatrix} 6 & -2 \\ -2 & 2 \end{pmatrix}$$

Özdegerler: $(6 - \lambda)(2 - \lambda) - 4 = 0 \;\Rightarrow\; \lambda^2 - 8\lambda + 8 = 0$

$$\lambda_1 \approx 6.83, \quad \lambda_2 \approx 1.17$$

İki özdeger de pozitif $\rightarrow$ Hessian **pozitif definit** $\rightarrow$ f konveks!

Örnek 3: Taylor Açılımı

Soru: $f(x) = x_1^2 + x_2^2$'yi $x = (1, 1)$ etrafında 2. derece Taylor ile yaklaş.

Çözüm: $f(1, 1) = 2$, $\nabla f(1, 1) = (2, 2)^T$, $\nabla^2 f = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}$

$p = (0.1, 0.1)$ adımı atarsak:

$$f(1.1, 1.1) \approx 2 + 0.4 + 0.02 = 2.42$$

Gerçek değer: $f(1.1, 1.1) = 2.42$ ✓

Örnek 4: Konvekslik Kontrolü

Soru: $f(x) = e^x$ fonksiyonunun konveks olduğunu göster.

Çözüm: $f''(x) = e^x > 0$ her yerde $\rightarrow$ **kesinlikle konveks**. ✓

Örnek 5: Özdeger Bulma

Soru: $A = \begin{pmatrix} 4 & 2 \\ 2 & 1 \end{pmatrix}$ matrisinin özdegerlerini bul.

Çözüm: $\det(A - \lambda I) = 0$:

$$(4 - \lambda)(1 - \lambda) - 4 = 0 \;\Rightarrow\; \lambda^2 - 5\lambda = 0 \;\Rightarrow\; \lambda_1 = 0,\; \lambda_2 = 5$$

$\lambda_1 = 0 \rightarrow v_1 = (1, -2)^T$. $\quad \lambda_2 = 5 \rightarrow v_2 = (2, 1)^T$.

$\lambda_1 = 0$ olduğu için A tekil (singular): $\det(A) = 0$. ✓

Örnek 6: LU Ayrışımı

Soru: $A = \begin{pmatrix} 2 & 1 \\ 4 & 3 \end{pmatrix}$ için LU ayrışımını bul, $Ax = b$'yi çöz ($b = (3,7)^T$).

Çözüm:

$$L = \begin{pmatrix} 1 & 0 \\ 2 & 1 \end{pmatrix}, \quad U = \begin{pmatrix} 2 & 1 \\ 0 & 1 \end{pmatrix}$$

$Ly = b$: $y = (3,1)^T$. $\quad Ux = y$: $\boxed{x = (1,1)^T}$

Örnek 7: Jacobian Hesaplama

Soru: $r(x_1, x_2) = (x_1^2 + x_2^2,\ x_1x_2,\ e^{x_1})$ için Jacobianı bul.

Çözüm:

$$J(x) = \begin{pmatrix} 2x_1 & 2x_2 \\ x_2 & x_1 \\ e^{x_1} & 0 \end{pmatrix}, \qquad J(1,1) = \begin{pmatrix} 2 & 2 \\ 1 & 1 \\ e & 0 \end{pmatrix}$$

Örnek 8: Koşul Sayısı

Soru: $A = \begin{pmatrix} 1 & 0 \\ 0 & 0.001 \end{pmatrix}$ matrisinin koşul sayısını bul.

Çözüm: $\kappa(A) = \|A\|_2 \cdot \|A^{-1}\|_2 = 1 \times 1000 = \boxed{1000}$

$\kappa(A) = 1000$ oldukça büyük $\rightarrow$ **ill-conditioned**.

Örnek 9: Konveks Kombinasyon

Soru: $A = (1,3)$ ve $B = (5,1)$ noktalarının konveks kombinasyonlarını hesapla.

Çözüm: $P = \lambda A + (1-\lambda)B$

$\lambda = 0.5$: $P = (3,2)$ (orta nokta). $\quad \lambda = 0.3$: $P = (3.8, 1.6)$ (B'ye daha yakın).

Örnek 10: Minimumu Bul

Soru: $f(x_1, x_2) = x_1^2 + x_2^2 - 2x_1 - 4x_2 + 5$ fonksiyonunun minimumunu bul.

Çözüm:

$$\nabla f = \begin{pmatrix} 2x_1 - 2 \\ 2x_2 - 4 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \Rightarrow x_1 = 1,\ x_2 = 2$$

$$\nabla^2 f = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix} \quad \text{(pozitif definit)} \Rightarrow \textbf{minimum!}$$

$$\boxed{f(1,2) = 1 + 4 - 2 - 8 + 5 = 0}$$